

데이터 분석 종합 보고서

타이타닉 생존 결정 요인 분석 및 예측 모델 수립

타이타닉 승객 명부 · 891건

분석 카테고리

정형 ML

주 모델

CatBoost

표본 수

891건

생성

2026-06-11

0.8620

검증 AUC

12

데이터 변수

목차

TABLE OF CONTENTS

Executive Summary

p.3

1 분석 개요

무엇을, 왜 분석하는가

p.4-5

2 데이터 이해

이 데이터로 답할 수 있는가

p.6

3 탐색적 발견 (EDA Insights)

무엇이 결과를 가르는가

p.7-9

4 분석 방법

믿을 수 있는 절차인가

p.10-11

5 모델 성능

단순 기준보다 나은가

p.12-13

6 핵심 인사이트와 해석

어디에 집중해야 하는가

p.14

7 비즈니스 임팩트와 실행

무엇을, 어떻게 실행하는가

p.15-16

8 결론

p.17

9 부록

p.18

9.1 세그먼트·해석

p.19

9.2 재현·데이터 정의

p.20

Executive Summary

타이타닉 승객 명부 데이터(891건) 분석 결과, '성별'은 '생존 여부'를 가장 크게 좌우하며 이를 예측할 근거를 확보했다.

관통 질문: '생존 여부' 판정 모델을 운영에 도입할 가치가 있는가? **답: 있다 (조건부)**

1. 무엇이 가르나 성별·좌석 등급이 가장 크게 가르다. 여성 74% 대 남성 19% (약 4배).
2. 얼마나 믿나 검증 AUC 0.86. 단순 추측을 결정적으로 상회해 도입 기준을 충족한다.
3. 얼마짜리인가 '3등 객실 남성' 집단을 '1등 객실 여성' 수준으로 끌어올리면 전체 사망률은 67%에서 59%로 감축된다.

EXHIBIT 1 · 핵심 비즈니스 KPI

표적 개입으로 사망률을 8%p(약 58건) 낮춘다.

82%

고위험군(3등·남성·청년)
사건 식별 정확도

8%p

사망률 감축

58건

사망 감축

기간: 연간 환산

출처: ADA 분석 · 주: 전환율 20% 가정(보수적), 추정치

권고

'3등 객실 남성' 고위험군에 표적 개입을 파일럿으로 시작하고, 성과 게이트 통과 시 단계 확대한다.

단, 데이터의 표본·기간 한계 안에서 유효하며 외삽은 보수적으로 본다.

1. 분석 개요

'Survived' 판정 모델을 운영에 도입할 가치가 있는가

핵심, 'Survived'를 가르는 신호가 데이터에 실제로 있고, 그 신호가 단순 추측을 의미 있게 넘느냐. 둘 다 '예'가 아니면 이 모델은 운영에 올릴 이유가 없다.

독자·용도

본 보고서는 분석·실무 담당자가 모델 도입 여부와 운영 적용 방식을 결정하는데 사용한다.

분석 배경

역사 재난 데이터 분석을 통해 사회·구조적 격차가 생존에 미친 영향을 정량화하고, 현대 재난 대응의 우선순위 설계·우선 구조 의사결정 알고리즘 설계의 근거 자료로 활용한다. 891건은 PoC·탐색에 충분, 운영 일반화엔 확대 필요. 이 판단의 판돈은 작지 않다. 옳게 가려내면 한정된 자원을 가장 중요한 대상에 집중하고, 놓치면 그 비용을 현장과 대상이 떠안는다.

분석 목적

정확한 'Survived' 판정을 자동화해 판정의 일관성과 속도를 확보하는 것이 목적이다. 이를 위해 수치형 5개·범주형 4개의 입력 변수로 'Survived'를 예측하는 모델을 수립하고, 결과를 좌우하는 핵심 변수를 규명한다. 단순 기준 모델 대비 실질적 개선과 해석 가능성을 함께 확보해, 결과를 운영 의사결정에 바로 활용할 수 있게 한다.

분석 범위

분석은 891행 × 12열을 대상으로 tabular_ml 관점의 예측에 한정한다. 식별자(PassengerId, Ticket)는 누수 방지를 위해 입력에서 제외한다. 표본이 891건 규모이므로 운영 환경의 분포 변화·미관측 세그먼트에 대한 일반화는 보수적으로 해석하며, 외부 환경 요인과 실시간 적용은 범위에서 제외한다.

성공 기준

무엇보다 단순 추측(단순 모델 0.62 수준)보다 의미 있게 나아야 도입할 가치가 있다. 어떤 오판이 더 비싼지에 맞춰 놓침·허경보 중 무엇을 우선 줄일지로

성패를 가린다. 끝으로 시기·집단을 바꿔도 성능이 유지돼야 운영에 쓸 수 있다. 거꾸로, 입력 변수를 더 늘려도 개선이 +2%p 이내라면 현재 구성으로 충분하다는 뜻이며, 그 선을 못 넘는 모델은 도입할 이유가 없다.

데이터 적합성 게이트

적합성 게이트	기준	실측	판정
표본 충분성	1,000건 이상 권장	891건	주의
결측 건전성	핵심변수 20% 미만	객실 번호 77%	주의
클래스 균형	소수 클래스 20% 이상	소수 38%	충족
타겟 정의	명확·단일	'Survived'	충족
누수 차단	식별자 입력 제외	PassengerId, Ticket 제외	충족

2개 항목 '주의', 탐색·방향성에는 충분하나 운영 확정 전 보완(표본 확대·결측 처리)이 필요하다.

2. 데이터 이해

891건·12개 변수로 결정에 충분한가

핵심, '객실 번호' 등 핵심 변수의 결측 처리가 결과를 좌우한다, 단순 대치로 신호를 지울 위험이 있다.

데이터 구성·적합성


분석 대상은 891행 × 12열로, 식별자·타깃을 제외하면 수치형 5개·범주형 4개의 입력 변수로 구성된다. 891건은 개념검증·탐색에는 충분하나 운영 일반화에는 표본 확대가 바람직하다. 식별자(PassengerId, Ticket)는 누수 방지를 위해 예측에서 제외한다. 타깃 'Survived'는 2개 클래스, 다수 클래스 비율 61.6%로 비교적 균형적이다.

변수 품질 진단

객실 번호 등 범주가 많은(준고유값) 변수는 그대로 원-핫 인코딩하면 차원이 폭증해 과적합을 부르므로, 의미 있는 상위 범주로 묶거나 파생 변수로 요약하거나 제거한다. 운임은 평균 대비 최댓값이 한참 커 우편향이 심해, 로그·분위 변환으로 소수 극단값이 모델을 끌고 가지 않게 한다. 나머지 변수는 분포·카디널리티가 안정적이라 표준 처리로 충분하다.

결측 진단

결측은 일부 변수에 집중되며(변수별 비율은 아래 그래프), 중앙값/최빈값으로 대체해 처리했다. 특히 결측률이 20%를 넘는 '객실 번호'는 무작위 결측(MCAR)으로 보기 어렵다, 결측 여부 자체가 특정 집단을 가르는 신호일 수 있어, 단순 대치로 지우기보다 '결측 플래그'로 피처화하는 편이 안전하다.




결측이 큰 변수일수록 단순 대치가 신호를 지울 위험이 크다.

3. 탐색적 발견 (EDA Insights)

1) 성별 생존률


핵심, '여성'의 생존율 74.2%가 '남성'(18.9%) 대비 약 3.9배, 결정적 갈림



관찰 생존율 여성 74.2%, 남성 18.9%. (n=891) 의미 집단 간 55.3%p 격차, 결과를 가르는 핵심 동인.

2) 좌석 등급별 생존률


핵심, '1등'의 생존율 63.0%가 '3등'(24.2%) 대비 약 2.6배, 결정적 갈림



관찰 생존율 1등 63.0%, 2등 47.3%, 3등 24.2%. (n=891) 의미 집단 간 38.8%p 격차, 결과를 가르는 핵심 동인.

3) 나이대별 생존률

핵심, '아동(≤ 12)'의 생존율 58.0%가 '노년(>60)'(22.7%) 대비 약 2.6배, 결정적 갈림



관찰 생존율 아동(≤ 12) 58.0%, 청소년 42.9%, 청년(19-35) 38.3%, 중년(36-60) 40.0%. (n=891) 의미 집단 간 35.3%p 격차, 결과를 가르는 핵심 동인.

4) 승선향별 생존률

핵심, '세르부르(C)'의 생존율 55.4%가 '사우샘프턴(S)'(33.7%) 대비 약 1.6배, 결정적 갈림



관찰 생존율 세르부르(C) 55.4%, 퀸스타운(Q) 39.0%, 사우샘프턴(S) 33.7%. (n=891) 의미 집단 간 21.7%p 격차, 결과를 가르는 핵심 동인.

5) 주요 발견 종합

핵심, 탐색이 가리키는 한 방향, 격차가 큰 동인이 곧 개입 우선순위다.

발견 종합

여러 탐색 축에서 생존이 특정 구간에 집중되는 공통 패턴이 나타난다. 1등 객실 여성 승객의 생존률이 96.8%로 최고치를 기록한다. 3등 객실 남성 청년(19-35세) 생존률이 12.1%로 최저, 표본 198명 중 24명만 생존. 핵심 동인은 카이제곱 검정에서 모두 유의($p < 0.001$ 유의)할 뿐 아니라 효과크기(격차·배수)도 커, 관측된 차이는 우연이 아니라 크고 실재하는 차이다, 상세는 아래 표.

비즈니스 의미

표적 개입: 격차가 가장 큰 집단에 자원을 집중해 결과를 효율적으로 개선한다.

우선순위: 동인별 격차 순서가 곧 개입 우선순위, 한정 자원의 효과를 극대화한다.

KPI 가시성: 개입 효과를 정량 추적해 경영진 KPI 보고를 정교화한다.

가설검정·효과크기 요약

동인	격차	효과크기	검정(p)	연관
성별 생존률	55%p	3.9배	$p < 0.001$ 유의	강함
좌석 등급별 생존률	39%p	2.6배	$p < 0.001$ 유의	강함
나이대별 생존률	35%p	2.6배	—	강함
승선향별 생존률	22%p	1.6배	—	중간

유의성(p)은 '우연이 아님', 효과크기(격차·배수)는 '얼마나 큰가', 둘 다 큰 동인이 개입 1순위.

4. 분석 방법

핵심, 객실 번호 77.1% 결측을 정보 손실 위험으로 제거, 다른 변수의 대리 신호로 보완

전처리

객실 번호(77.1% 결측)은 정보 손실 위험으로 컬럼 제외했다. 단순 대치 시 신호가 변형되며, 관련 정보는 다른 변수가 부분적으로 대리한다. 나이 결측은 전체 중앙값이 아니라 그룹 중앙값으로 대치했다, 세그먼트별 신호를 보존하기 위함이다. 그 외 6단계 세부 결정은 아래 표에서 일괄 확인한다. 모든 변환 통계는 학습 데이터로만 적합해 검증 누수를 차단했다.

피처 엔지니어링

파생 피처 4개를 생성했다, 생성 방식과 근거는 표로 정리했다. 인코딩·파생·제거를 거쳐 최종 15개 피처로 수렴했다, 저분산·중복·누수 위험 변수 2개 제거. 피처 선택은 중요도 기반 상위 K + 다중공선성 제거를 적용했다.

전처리 단계

#	단계	대상	근거
1	impute_numeric	Age	결측 19.87%, 성별·등급 그룹 중앙값으로 대치
2	drop	Cabin	결측 77.10% — 정보 손실 위험으로 제외, 등급(Pclass)이 대리 신호
3	impute_categorical	Embarked	결측 2건 최빈값(S) 대치
4	encode_categorical	Sex, Embarked, Pclass	범주형 원-핫 인코딩
5	scale_numeric	Age, Fare	표준화
6	drop_id	PassengerId, Ticket, Name	식별자 누수 방지

적용 순서·대상·근거

검증 설계

다수 클래스 비율 61.6% 분포를 검증셋이 대표하도록 층화 분할을 적용했다. 전처리는 분할 내부에서 적합(파이프라인화)해 검증 정보가 학습에 새지 않게 했다. 타깃 누수 점검 2건 모두 통과 (2/2).

평가 지표

검증 AUC을 주지표로 채택했다. F1·PR-AUC와 운영 임계값을 함께 본다. 단순 추측(61.6%)을 명확히 넘어서는 수준을 요구하며, 오판 비용 비대칭에 맞춰 임계값을 조정한다.

생성 피처

피처	생성 방식	근거
Title	Name에서 호칭 추출(Mr/Mrs/Miss/Master)	성별·연령 결합 신호로 작용
FamilySize	SibSp + Parch + 1	동승 가족 규모는 생존 동학에 영향
IsAlone	FamilySize == 1	단독 승객의 생존 패턴이 다름
AgeBin	아동(≤ 12)/청소년/청년/중년/노년 구간화	구간별 생존 격차 포착

원본에서 파생한 신호 변수, 도메인 가설을 피처로 인코딩.

5. 모델 성능

핵심, 'CatBoost' 모델이 후보·기준선을 의미 있게 넘어 운영 도입 기준을 충족한다

선정 근거

'CatBoost'를 최종 선정했다. 범주형(Sex·Embarked·Pclass)을 인코딩 없이 순서형 부스팅으로 직접 처리하고, 891건 소표본에서도 정규화가 강해 과적합을 억제한다. 결측과 비선형 상호작용에 강건하며, 추가 튜닝의 한계 효용까지 고려해 선정했다. 범주형 자동 처리·소표본 안정성. 후보 4개 중 1위로 2위 XGBoost(0.8510)를 +0.0110 앞섰다. 범주형·결측·비선형 상호작용에 강하고 불균형에서도 안정적인 부스팅 계열이다.

후보 탈락 사유

XGBoost 모델은 검증 0.8510로 본 모델에 0.0110 못 미쳤다, 범주형을 직접 다루지 못해 원-핫 인코딩이 필요하고, 891건 소표본에서 트리를 깊게 키우면 학습-검증 격차가 벌어지는 과적합 신호를 보였다.

RandomForest 모델은 검증 0.8420로 본 모델에 0.0200 못 미쳤다, 배경 특성상 확률 출력의 보정이 약해 임계값을 의사결정에 바로 쓰기 어렵고, 나이×등급×성별 같은 고차 상호작용 포착이 부스팅 계열보다 약했다.

LogReg 모델은 검증 0.8210로 본 모델에 0.0410 못 미쳤다, 선형 결정경계라 등급·성별·나이의 결합(비선형) 효과를 구조적으로 담지 못해, 해석은 쉬우나 본 데이터에서 성능 상한이 분명했다.

모델 후보 비교

모델	검증 AUC	판정
CatBoost	0.8620	선정
XGBoost	0.8510	탈락 — 범주형을 직접 다루지 못해 원-핫 인코딩이 필요하고, 891건 소표본에서 트리를 깊게 키우면 학습-검증 격차
RandomForest	0.8420	탈락 — 배경 특성상 확률 출력의 보정이 약해 임계값을 의사결정에 바로 쓰기 어렵고, 나이×등급×성별 같은 고차 상호
LogReg	0.8210	탈락 — 선형 결정경계라 등급·성별·나이의 결합(비선형) 효과를 구조적으로 담지 못해, 해석은 쉬우나 본 데이터에서

최종 선정 모델과 탈락 후보, 성능과 안정성을 함께 본 결과.

업계 벤치마크 대비

유사 이진분류 공개 벤치마크 평균 AUC 0.80 대비 본 모델 0.86, 상위(격차 +0.06).

확률 신뢰도(보정)


모델이 제시하는 확률이 실제 적중률과 잘 맞아 (ECE 0.034), 확률을 그대로 임계값·의사결정에 쓸 수 있다.

오류 프로파일

오류는 주로 '농침' 쪽이다(미탐 98건 > 오탐 61건). 농침 비용이 크면 임계값을 낮춰 재현율을 높이는 운영을 권고한다.

검증 성능

검증 AUC 0.86 (n=891). 전체 지표와 95% 신뢰구간은 부록 9.1(재현 정보)에 수록.



본 모델이 무작위·단순률을 의미 있게 상회, 도입 가치의 근거.

6. 핵심 인사이트와 해석

무엇이 'Survived'를 결정하며, 어디를 보강해야 하는가

핵심, 전체 사망의 64%가 '3등 객실 남성' 한 세그먼트에서 발생한다, 전반의 문제가 아니라 한 구간의 문제다.

무엇이 가른다

'여성' 생존율(74%)이 '남성'(19%)의 4배로, 이 구간이 갈림의 핵심이다. 성별·좌석 등급 두 축이 결과를 함께 끌고 가는 다요인 구조다.

왜 그런가 — 메커니즘

관측된 격차의 배경은 다음으로 해석된다. 성별: 여성 우선 구조 정책('여성과 어린이 먼저')이 생존을 가른 1차 변수다. 좌석 등급: 상위 등급은 상갑판 근접 + 구명정 접근성으로 구조 기회가 구조적으로 높았다. 나이: 아동 우선 구조와 노년 신체 한계가 양 극단의 격차를 만들었다.

누구에 집중하나

가장 위험한 마이크로-세그먼트는 '3등 객실 남성'(347건, 사망률 86.5%). 1등 객실 여성·아동이 최저 위험군, 96.8% 생존. 3등 객실 남성 청년(19-35세) 생존률이 12.1%로 최저, 표본 198명 중 24명만 생존.

개별 예측 사례

예측을 개별 사례로 트레이스하면, '사망' 예측 (근거: 성별 남성, 좌석 등급 3등); '생존' 예측 (근거: 성별 여성, 좌석 등급 1등). 전체 사례는 부록 9.1에 있다.

가장 큰 레버

'3등 객실 남성' 집단의 20%를 '1등 객실 여성' 수준으로 전환하면 연 약 58건의 사망을 줄여 전체 사망률을 67.3%에서 58.9%로 낮춘다. (가정: 전환율 20%, 전환 후 사망률은 '1등 객실 여성' 수준 적용)

7. 비즈니스 임팩트와 실행

지금부터 누가 무엇을 언제까지 할 것인가

핵심, '3등 객실 남성' 집단을 표적해 전체 생존율을 8.3%p 낮추는 것이 가장 큰 레버다.

임팩트

고위험군(3등·남성·청년) 사전 식별 정확도 82 % 수준의 효과가 정량적으로 기대된다. 정확한 'Survived' 판정을 자동화해 고위험·고우선 대상의 선별·처리에 일관성과 속도를 확보한다. '3등 객실 남성' 집단의 20%를 '1등 객실 여성' 수준으로 전환하면 연 약 58건의 사망을 줄여 전체 사망률을 67.3%에서 58.9%로 낮춘다. (가정: 전환율 20%, 전환 후 사망률은 '1등 객실 여성' 수준 적용)

재무 임팩트 (ROI·페이백)

효익의 정량 근거는 위 임팩트의 연 58건 생존 감축 추정이며, 여기에 건당 비용을 곱하면 방어 가능한 손실 규모가 산출된다. 정확한 ROI와 페이백은 건당 비용·표적군 규모·전환율 가정을 입력해야 확정되며, 운영 결재 전 이 세 값의 합의를 권고한다.

표적 개입 원칙

전수가 아니라 모델이 점수화한 고위험 상위군을 선별하고, 그중 고가치(매출·전략) 대상을 우선한다. 본 데이터에선 '3등 객실 남성' 집단이 1순위 표적이다.

실행 레버

우선순위가 높은 실행 레버는 다음과 같다.

'3등 객실 남성' 집단을 '1등 객실 여성' 수준으로 끌어올리는 표적 개입 시, 전체 사망률이 67.3%에서 58.9%로 8.3%p 감소.

운영 임계값 조정 시, 놓침·헛개입 비용에 맞춰 정밀도·재현율 균형점 설정.

좌석 등급 데이터 강화 시, 핵심 동인 관련 수집·관리를 보강해 예측력 개선.

운영 적용

운영에는 'CatBoost' 모델을 검증 AUC 0.8620 기준으로 적용하되, 분포 변화에 대응할 6개월 재검증 주기를 함께 둔다. 학습 표본이 1912년 단일 항해라 다른 시대·상황 적용 시 입력 분포가 달라질 수 있다. 이에 드리프트 감지 시 정기 주기와 별개로 즉시 재학습을 트리거한다. 동시에 성별, 좌석 등급 등 핵심 동인의 모니터링·수집을 강화해 예측력과 개입 정확도를 지속 개선한다.

파일럿 (표적군 한정)

개입은 전면이 아니라 '3등 객실 남성' 고위험군부터 파일럿한다, 이 집단에서 사망률이 개입 후 유의하게 낮아지는지를 6개월 안에 비개입 대조군과 비교 측정하고, 효과가 확인된 레버만 인접 고위험군으로 확대하며 효과 없는 레버는 폐기한다.

거버넌스 (결재·책임)

임계값·재학습 정책 변경은 모델 소유 부서가 기안하고 데이터·리스크 검토를 거쳐 운영 책임자가 결재하며, 임계 이탈 시 재학습·롤백 권한과 책임 소재를 사전에 명시한다.

리스크·전제

단, 표본 891명은 모델링 가능하나 단일 사건의 단일 시점 데이터로 시대·상황 외삽이 제한적이다. Cabin 77% 결측, 객실 위치(갑판) 신호가 모델에 미반영, 등급(Pclass)이 부분 대리만 수행. 구명정 배정·승선 순서 등 시점 정보가 누락돼 시간 동학을 추적할 수 없다. 위 권고는 이 전제 위에서 유효하다.

8. 결론

'CatBoost' 모델, 운영 도입할 가치가 있는가

핵심, 데이터는 성별, 좌석 등급이 'Survived'를 가르다고 단정한다.
권고는 분명하다, 'CatBoost' 모델을 AUC 0.8620 기준으로 운영 도입한다.

고위험 상위군 '3등 객실 남성' 표적 개입 운영 모델로 전환한다. 전환을 가정별 정량 효과(감축 건수·결과율 변화)는 아래 표로 정리했다.

이 감축분은 결정을 미루는 만큼 매년 방어 가능했던 손실로 그대로 누적된다.
분기를 넘기면 분포가 변해 본 분석의 결정 근거 자체가 약해진다.

단, 표본 891명은 모델링 가능하나 단일 사건의 단일 시점 데이터로 시대·상황 외삽이 제한적이다. 위 권고는 이 전제 위에서 유효하다.

운영 후 검증 AUC · 성별, 좌석 등급 분포 · 생존율을 월 단위로 추적하고, 임계 이탈 시 정기 재학습 트리거를 가동한다.

시나리오별 정량 임팩트

시나리오	사망 감축	전체 사망률
보수 · 전환율 10%	29건	67.3% → 63.1%
기준 · 전환율 20%	58건	67.3% → 58.9%
적극 · 전환율 30%	87건	67.3% → 54.8%

'3등 객실 남성'의 일부를 '1등 객실 여성' 수준으로 전환 시 사망 감축, 전환율 가정별 민감도.

9. 부록

핵심, 본문 결론을 독립 검증하는 기술 자료, 본문은 반올림 헤드라인, 부록은 전 지표 4자리 + 95% CI와 오류·세그먼트 진단.

주지표뿐 아니라 전 지표를 정밀값과 95% 신뢰구간으로 본다, 점추정이 아니라 구간으로 신뢰도를 판단한다.

검증 지표 전체 (95% CI)

지표	값	95% CI
검증 AUC	0.8620	0.8394 - 0.8846
검증 PR-AUC	0.8100	0.7842 - 0.8358
검증 F1	0.7800	0.7528 - 0.8072
검증 재현율	0.7400	0.7112 - 0.7688
검증 정밀도	0.8200	0.7948 - 0.8452
검증 정확도	0.8300	0.8053 - 0.8547

정규근사 95% 신뢰구간 · N=891.

지표가 '얼마나 맞나'라면, 혼동행렬은 '어디서 틀리나', 정탐(TP)·오탐(FP)·미탐(FN)·정상기각(TN)의 건수 분포로 오류의 성격을 본다.

혼동행렬 (검증셋)

True 0	TN 452	FP 61
True 1	FN 98	TP 280
	Pred 0	Pred 1

미탐(FN) 98 > 오탐(FP) 61, 놓침 우세. 미탐 비용이 크면 임계값을 낮춰 재현율 우선.

9.1 세그먼트·해석

핵심, 누구에게서 틀리고, 어떤 변수가 결과를 지배하는지, 코호트 위험과 변수 기여.

코호트별로 결과율이 얼마나 갈리는지, 표적 개입 우선순위의 근거.


세그먼트별 성능

세그먼트	규모(n)	사망률
3등 객실 남성	347	86.5%
3등 객실 여성	144	50.0%
2등 객실 남성	108	84.3%
1등 객실 여성	94	3.2%

코호트 간 결과율 격차가 큼, 전수가 아니라 표적 개입이 효율적. 확률 보정 ECE 0.034(통상 0.05 이하 양호), 모델 점수를 임계값에 직접 사용 가능.

피쳐 중요도는 모델이 각 변수에 부여한 기여도, 무엇이 결정을 지배하는지.

피쳐 중요도



상위 2개(Sex, Pclass)가 전체 중요도의 58%, 결정 지배.

9.2 재현·데이터 정의

핵심, 결과를 동일 조건에서 재현하는 정보와, 분석에 쓰인 전체 변수의 유형·결측·역할.

동일 모델·환경·분할 기준에서 본문 수치가 그대로 재현된다.

재현 정보·환경

항목	값
주 모델	CatBoost
평가 지표	검증 AUC 0.8620
데이터셋	891건 x 12변수 · 타겟 Survived
검증 방식	학습·검증 분할 · 전처리는 분할 내부 적합(누수 차단)

동일 환경·명령에서 본문 수치 재현.

분석에 쓰인 전체 변수의 유형·결측률·역할, 데이터 추적과 재현의 기준.

전체 변수 사전

변수	유형	결측	역할
승객 ID	수치형	0%	식별자
생존 여부	수치형	0%	타겟
좌석 등급	수치형	0%	입력
성명	범주형	0%	입력
성별	범주형	0%	입력
나이	수치형	19.9%	입력
형제·배우자 동승 수	수치형	0%	입력
부모·자녀 동승 수	수치형	0%	입력
티켓 번호	범주형	0%	식별자
운임	수치형	0%	입력
객실 번호	범주형	77.1%	입력
승선항	범주형	0.2%	입력

12개 변수 · 결측률은 프로파일러 산출값.